

Аналитический отчет по результатам исследования

В ходе работы мы подготовили данные: заполнили пропуски, удалили выбросы по массе молекулы, сгруппировали разреженные химические фрагменты и убрали сильно скоррелированные признаки. Затем проверили работу классических алгоритмов машинного обучения на двух задачах: регрессии (предсказание точных значений) и классификации (разделение данных на категории).

Анализ моделей регрессии

Предсказывать точные числа у алгоритмов не вышло.

На задаче IC50 лучший результат показал метод опорных векторов, но метрика R2 составила всего 0.196 при высокой ошибке (MAE = 68.1).

Чуть лучше дела обстоят у CC50, тут случайный лес выдал $R2 = 0.473$.

Предсказание SI провалилось полностью (максимальный $R2 = 0.14$ у линейной регрессии).

Вывод по регрессии: зависимость между признаками и точными значениями слишком сложная и зашумленная. Использовать эти модели на практике нельзя, они не улавливают закономерности.

Анализ моделей классификации

Также мы проверили работу алгоритмов классификации, предварительно разделив значения целевых переменных по медиане и порогу (>8). Здесь результаты оказались намного успешнее.

Для CC50 случайный лес показал отличный результат ($ROC-AUC = 0.861$ и $Accuracy = 0.774$). Деревья справились с разделением классов, эту модель можно брать в работу.

Для IC50 в лидеры выбился метод опорных векторов ($ROC-AUC$ составил 0.809, а $Accuracy$ держится на уровне 0.72). Модель хорошо разделяет объекты на нужные категории.

SI (по медиане и больше 8). Это самый сложный таргет. Если делить по медиане, то лучший алгоритм (SVC) дает ROC-AUC 0.719 и Accuracy 0.677. Но как только мы пытаемся искать объекты с высоким индексом ($SI > 8$), метрика F1 у всех моделей резко падает до 0.42-0.56. Лучшим оказался алгоритм KNN (ROC-AUC 0.734 и $F1 = 0.567$), но падение F1 говорит о том, что из-за нехватки нужных молекул в датасете возникает дисбаланс, и алгоритмы часто выдают ложные срабатывания.

Вывод по классификации: в отличие от регрессии, модели хорошо улавливают общие тенденции и могут успешно разбивать данные на классы. Основная сложность заключается лишь в несбалансированности выборки при поиске редких значений.

Итоговое обоснование выбора

Для прогнозирования CC50 лучшим решением является Случайный лес, так как он дал самые высокие и стабильные метрики. Для прогнозирования IC50 оптимально использовать метод опорных векторов. Классические регрессионные модели мы отбрасываем полностью из-за низкого качества предсказаний.

Рекомендации по продолжению исследования

1. Решить проблему дисбаланса при предсказании $SI > 8$. Нужно добавить балансировку весов внутри самих моделей (например, использовать параметр `class_weight='balanced'`).
2. Попробовать более мощные алгоритмы градиентного бустинга: XGBoost, LightGBM или CatBoost.
3. Расширить набор данных. Текущих признаков немного не хватает для точного предсказания, поэтому стоит попробовать добавить новые структурные или химические характеристики.